Strict Turnstile + α-Bounded Deletion 下频率估计算法的设计与理论分析

目录

1 模型与基本恒等式 **2**

1.1 数据流模型 2

1.2 由 strict turnstile + α-property 推出的两个基本不等式 2

2 Double-MG：Misra–Gries 的双摘要扩展 **3**

2.1 算法思想 3

2.2 插入流上 MG 的基本界与 residual bound 3

2.3 Double-MG 的基本误差界 5

2.4 Double-MG 的 residual bound 6

3 Double-SS：Space-Saving 的双摘要扩展 **6**

3.1 算法设计 6

3.2 误差界 7

4 Integrated SpaceSaving± **8**

4.1 算法设计 8

4.2 关键不变量与误差界 9

5 Count-Min Sketch 在 strict turnstile 与 α-bounded 下的理论保证 **12**

5.1 算法 12

5.2 strict turnstile 下的点查询保证 12

5.3 α-bounded strict turnstile 下的结论 13

6 Count-Sketch 在 strict turnstile 与 α-bounded 下的理论分析 **14**

6.1 算法定义 14

6.2 单行无偏性 14

6.3 单行方差界 15

6.4 高概率点查询界 15

6.5 Tail-F_2 形式的更细误差界 16

6.6 strict turnstile 与 α-bounded deletion 下的含义 17

7 小结 17

1 模型与基本恒等式

1.1 数据流模型

设数据流由一系列更新 (e_t, v_t) 组成，其中 $e_t \in U$，$v_t \in \mathbb{Z}$。对任意元素 e，其最终频率定义为

$$f_e = \sum_{t:e_t=e} v_t.$$

本文考虑 strict turnstile model，即任意时刻任意元素的真实频率都满足

$$f_e^{(t)} \geq 0.$$

进一步，设每个元素的总插入量与总删除量分别为

$$p_e, \qquad d_e,$$

则最终频率

$$f_e = p_e - d_e \geq 0.$$

定义

$$I = \sum_e p_e, \qquad D = \sum_e d_e, \qquad F_1 = \sum_e f_e.$$

由于是 strict turnstile，

$$F_1 = \sum_e (p_e - d_e) = I - D.$$

同时我们假设数据流满足 α-bounded deletion property：

$$I + D \leq \alpha F_1.$$

1.2 由 strict turnstile + α-property 推出的两个基本不等式

命题 1.1. *在 strict turnstile 且满足 α-bounded deletion 的条件下，*

$$I \leq \frac{\alpha+1}{2} F_1, \qquad D \leq \frac{\alpha-1}{2} F_1.$$

证明. 因为

$$I - D = F_1, \qquad I + D \leq \alpha F_1.$$

于是

$$I = \frac{(I+D)+(I-D)}{2} \leq \frac{\alpha F_1 + F_1}{2} = \frac{\alpha+1}{2} F_1.$$

同理

$$D = \frac{(I+D)-(I-D)}{2} \leq \frac{\alpha F_1 - F_1}{2} = \frac{\alpha-1}{2} F_1.$$

□

注 1.2. 后面所有 “$O(\alpha/\varepsilon)$ 空间得到 $|\hat{f}_e - f_e| \leq \varepsilon F_1$” 的结论，本质上都来自：

$$|\hat{f}_e - f_e| \lesssim \frac{I+D}{k} \leq \frac{\alpha F_1}{k}.$$

因此只要令 $k = \Theta(\alpha/\varepsilon)$ 即可。

2 Double-MG：Misra–Gries 的双摘要扩展

2.1 算法思想

将原始 strict-turnstile 流分成两条 insertion-only 子流：

- 正流 σ^+：保留所有正更新；
- 负流 σ^-：把所有负更新 -1 看成删除流中的一次正单位更新。

于是对任意元素 e，

$$f_e = p_e - d_e.$$

Double-MG 使用两个 MG 摘要：

- MG^+：处理正流，估计 p_e；
- MG^-：处理负流，估计 d_e。

查询时返回

$$\hat{f}_e^{\text{raw}} = \hat{p}_e - \hat{d}_e, \qquad \hat{f}_e = \max\{\hat{f}_e^{\text{raw}}, 0\}.$$

注 2.1. 因为真实值 $f_e \geq 0$，截断不会增大误差：

$$|\max\{x, 0\} - f_e| \leq |x - f_e|.$$

所以只需分析未截断误差。

2.2 插入流上 MG 的基本界与 residual bound

引理 2.2 (MG 基本界)**.** *对 insertion-only 流，若 MG 使用 k 个 counters，则对任意元素 i，*

$$0 \leq f_i - \hat{f}_i \leq \frac{N}{k+1},$$

其中 N 是该 insertion-only 流的总质量。

证明. MG 从不高估，因此 $0 \leq f_i - \hat{f}_i$。

设整个过程中触发了 Δ 次 “所有 counters 同时减 1” 操作。对任意元素，低估量最多就是它被这些全体减一操作影响的次数，因此

$$f_i - \hat{f}_i \leq \Delta.$$

另一方面，每触发一次全体减一操作，都意味着：

- 当前有一个新到达的单位更新；
- 当前 k 个 counters 全满。

这一次操作等价于“消去”了 $k+1$ 个单位质量：新到达的那个单位，加上已有的 k 个 counters 各减去 1。因此总质量 N 至少能支付所有这些消去：

$$\Delta(k+1) \le N.$$

故

$$\Delta \le \frac{N}{k+1}.$$

综上，

$$0 \le f_i - \hat{f}_i \le \frac{N}{k+1}.$$

□

定义 2.3. 设 insertion-only 流中按频率降序排序后，前 j 个元素的频率为

$$f_{(1)} \ge f_{(2)} \ge \cdots,$$

定义 residual mass

$$N_{\mathrm{res}}(j) = \sum_{r>j} f_{(r)}.$$

引理 2.4 (MG 的 residual bound)**.** *对 insertion-only 流，若 MG 使用 k 个 counters，则对任意 $j<k$ 及任意元素 i，*

$$0 \le f_i - \hat{f}_i \le \frac{N_{\mathrm{res}}(j)}{k+1-j}.$$

证明. 令 H 为该流中频率最高的 j 个元素组成的集合，$|H| = j$。设 Δ 为整个算法过程中触发全体减一操作的次数。

我们先证明

$$\Delta \le \frac{N_{\mathrm{res}}(j)}{k+1-j}.$$

考虑任意一次全体减一操作。设触发它的当前到达元素为 x。此时表中恰有 k 个已占用 counters，且 x 当前不在 summary 中。

分两种情况讨论：

情况 1：$x \notin H$. 当前 k 个 monitored 元素中，最多只有 j 个属于 H，因此至少有 $k-j$ 个 monitored 元素不属于 H。再加上当前到达元素 x 本身也不属于 H，所以这一次全体减一操作至少消去了

$$(k-j)+1 = k+1-j$$

个来自 $U \setminus H$ 的单位质量。

情况 2：$x \in H$. 由于 $x \in H$ 但当前却不在 summary 中，所以当前 k 个 monitored 元素里，属于 H 的元素最多只有 $j-1$ 个。故至少有

$$k-(j-1) = k+1-j$$

个 monitored 元素不属于 H。这一次全体减一操作同样至少消去了 $k+1-j$ 个来自 $U \setminus H$ 的单位质量。

因此，每一次全体减一操作至少消去 $k+1-j$ 个 residual units。

接下来说明这些被消去的 residual units 不会重复计数。每个 counter 的数值都可以理解为：该元素此前到达过、但尚未被某次全体减一抵消掉的“未匹配单位”。一次全体减一会从每个受影响的 non-H counter 中拿走一个这样的未匹配单位；若触发元素本身也在 $U \setminus H$ 中，则再额外拿走当前这个到达单位。一个单位一旦被消去，就不会在之后再次被消去。

因此整个算法中，被消去的 residual units 总数不超过 residual mass $N_{\text{res}}(j)$，于是

$$\Delta(k+1-j) \le N_{\text{res}}(j),$$

即

$$\Delta \le \frac{N_{\text{res}}(j)}{k+1-j}.$$

最后，对任意元素 i，其低估量至多为 Δ，故

$$0 \le f_i - \hat{f}_i \le \frac{N_{\text{res}}(j)}{k+1-j}.$$

□

2.3 Double-MG 的基本误差界

定理 2.5 (Double-MG 基本界)**.** *设正流与负流各使用一个 k-counter 的 MG 摘要，则对任意元素 e，*

$$|\hat{f}_e - f_e| \le \frac{I+D}{k+1} \le \frac{\alpha F_1}{k+1}.$$

因此只要

$$k+1 \ge \frac{\alpha}{\varepsilon},$$

就有

$$|\hat{f}_e - f_e| \le \varepsilon F_1.$$

证明. 对正流应用引理 2.2：

$$0 \le p_e - \hat{p}_e \le \frac{I}{k+1}.$$

对负流应用引理 2.2：

$$0 \le d_e - \hat{d}_e \le \frac{D}{k+1}.$$

于是

$$|f_e - \hat{f}_e| = |(p_e - \hat{p}_e) - (d_e - \hat{d}_e)| \le |p_e - \hat{p}_e| + |d_e - \hat{d}_e| \le \frac{I+D}{k+1}.$$

再由 α-property，

$$I + D \le \alpha F_1.$$

故

$$|f_e - \hat{f}_e| \le \frac{\alpha F_1}{k+1}.$$

当 $k+1 \ge \alpha/\varepsilon$ 时，得到

$$|f_e - \hat{f}_e| \le \varepsilon F_1.$$

□

2.4 Double-MG 的 residual bound

定义正流和负流各自的 residual masses：

$$I_{\text{res}}(j) = \text{正流中去掉 top-}j\text{ 后的剩余总插入量},$$

$$D_{\text{res}}(j) = \text{负流中去掉 top-}j\text{ 后的剩余总删除量}.$$

定理 2.6 (Double-MG residual bound)**.** *设正流与负流分别使用 k_+, k_- 个 counters 的 MG 摘要。则对任意 $j_+ < k_+$、$j_- < k_-$，*

$$|f_e - \hat{f}_e| \le \frac{I_{\text{res}}(j_+)}{k_+ + 1 - j_+} + \frac{D_{\text{res}}(j_-)}{k_- + 1 - j_-}.$$

特别地，若两边都取相同的 k 和 j，则

$$|f_e - \hat{f}_e| \le \frac{I_{\text{res}}(j) + D_{\text{res}}(j)}{k + 1 - j}.$$

证明. 分别对正流和负流应用引理 2.4：

$$0 \le p_e - \hat{p}_e \le \frac{I_{\text{res}}(j_+)}{k_+ + 1 - j_+},$$

$$0 \le d_e - \hat{d}_e \le \frac{D_{\text{res}}(j_-)}{k_- + 1 - j_-}.$$

因此

$$\begin{aligned} |f_e - \hat{f}_e| &= |(p_e - \hat{p}_e) - (d_e - \hat{d}_e)| \le |p_e - \hat{p}_e| + |d_e - \hat{d}_e| \\ &\le \frac{I_{\text{res}}(j_+)}{k_+ + 1 - j_+} + \frac{D_{\text{res}}(j_-)}{k_- + 1 - j_-}. \end{aligned}$$

若 $k_+ = k_- = k$ 且 $j_+ = j_- = j$，则得到简化形式。 □

3 Double-SS：Space-Saving 的双摘要扩展

3.1 算法设计

Double-SS 使用两个 insertion-only 的 Space-Saving 摘要：

- SS^+：处理正流；
- SS^-：处理负流。

查询时先计算

$$\hat{f}_e^{\text{raw}} = \hat{p}_e - \hat{d}_e,$$

再输出

$$\hat{f}_e = \max\{\hat{f}_e^{\text{raw}}, 0\}.$$

Algorithm 1 Double-SS

```
维护两个 Space-Saving 摘要 SS^+, SS^-
for 每个更新 (e, v) do
    if v > 0 then
        将元素 e 插入到 SS^+ 中 v 次（若考虑单位更新）
    else
        将元素 e 插入到 SS^- 中 |v| 次
    end if
end for
查询：
```

$$\hat{f}_e = \max\{\mathrm{Query}(SS^+, e) - \mathrm{Query}(SS^-, e),\ 0\}.$$

3.2 误差界

引理 3.1 (插入流上的 Space-Saving 基本界)**.** *对 insertion-only 流，若 Space-Saving 使用 m 个 counters，则对任意元素 e，*

$$0 \le \hat{f}_e - f_e \le \frac{F_1}{m}.$$

注 3.2. Space-Saving 是单边过估计，而 MG 是单边低估。

定理 3.3 (Double-SS 的分配式误差界)**.** *若正流与负流分别使用 m_I, m_D 个 counters 的 Space-Saving 摘要，则对任意元素 e，*

$$|\hat{f}_e - f_e| \le \frac{I}{m_I} + \frac{D}{m_D}.$$

因此若取

$$m_I \ge \frac{\alpha+1}{2\varepsilon}, \qquad m_D \ge \frac{\alpha-1}{2\varepsilon},$$

则

$$|\hat{f}_e - f_e| \le \varepsilon F_1.$$

证明. 由引理 3.1，存在

$$\eta_e^+, \eta_e^- \ge 0$$

使得

$$\hat{p}_e = p_e + \eta_e^+, \qquad 0 \le \eta_e^+ \le \frac{I}{m_I},$$

$$\hat{d}_e = d_e + \eta_e^-, \qquad 0 \le \eta_e^- \le \frac{D}{m_D}.$$

于是未截断估计满足

$$\hat{f}_e^{\mathrm{raw}} - f_e = (\hat{p}_e - \hat{d}_e) - (p_e - d_e) = \eta_e^+ - \eta_e^-.$$

因此

$$|\hat{f}_e^{\mathrm{raw}} - f_e| \le \eta_e^+ + \eta_e^- \le \frac{I}{m_I} + \frac{D}{m_D}.$$

又因为 $f_e \geq 0$，截断到 0 不会增大误差，所以

$$|\hat{f}_e - f_e| \leq |\hat{f}_e^{\text{raw}} - f_e| \leq \frac{I}{m_I} + \frac{D}{m_D}.$$

再由命题 1.1，

$$\frac{I}{m_I} + \frac{D}{m_D} \leq \frac{\alpha+1}{2m_I}F_1 + \frac{\alpha-1}{2m_D}F_1.$$

令

$$m_I \geq \frac{\alpha+1}{2\varepsilon}, \qquad m_D \geq \frac{\alpha-1}{2\varepsilon},$$

则

$$|\hat{f}_e - f_e| \leq \varepsilon F_1.$$

□

推论 3.4 (Double-SS 的同尺寸版本)**.** *若正流与负流都使用 m 个 counters，则*

$$|\hat{f}_e - f_e| \leq \frac{I+D}{m} \leq \frac{\alpha F_1}{m}.$$

因此只要

$$m \geq \frac{\alpha}{\varepsilon},$$

就有

$$|\hat{f}_e - f_e| \leq \varepsilon F_1.$$

4 Integrated SpaceSaving±

4.1 算法设计

Integrated SpaceSaving± 只维护一个 summary，但每个 monitored item e 记录两个值：

$$(\text{ins}_e, \text{del}_e).$$

更新规则如下：

1. 若 e 已在 summary 中：
   - 插入：$\text{ins}_e \leftarrow \text{ins}_e + 1$；
   - 删除：$\text{del}_e \leftarrow \text{del}_e + 1$。
2. 若 e 不在 summary 中且 summary 未满：

$$(\text{ins}_e, \text{del}_e) \leftarrow (1, 0).$$

3. 若 e 不在 summary 中、summary 已满、且当前操作是插入：
   - 找到 insert 计数最小的条目 x，记其值为 $w = \text{ins}_x$；
   - 驱逐 x；

- 插入 e，并设置
$$(\mathrm{ins}_e, \mathrm{del}_e) \leftarrow (w+1, 0).$$

4. 若 e 不在 summary 中、summary 已满、且当前操作是删除：忽略该删除。

查询时，
$$\hat{f}_e = \begin{cases} \mathrm{ins}_e - \mathrm{del}_e, & e \in S, \\ 0, & e \notin S. \end{cases}$$

4.2 关键不变量与误差界

设当前 summary 中最小的 insert 计数为
$$m_t = \min_{x \in S_t} \mathrm{ins}_x.$$

引理 4.1 (Integrated SpaceSaving± 的关键不变量)**.** *在任意时刻 t，对任意元素 e：*

1. *若 e 当前被监控，则*
$$f_e^{(t)} \le \hat{f}_e^{(t)} \le f_e^{(t)} + m_t.$$

2. *若 e 当前未被监控，则*
$$f_e^{(t)} \le m_t.$$

因此任意元素都满足
$$|\hat{f}_e^{(t)} - f_e^{(t)}| \le m_t.$$

证明. 对更新次数做归纳。

初始时刻. summary 为空，不变量显然成立。

归纳步. 假设更新前不变量成立，讨论当前更新。

情况 1：元素 e 已在 summary 中。若是插入，则真实频率与估计值同时加 1；若是删除，则真实频率与估计值同时减 1（准确地说，del_e 加 1，故 $\hat{f}_e = \mathrm{ins}_e - \mathrm{del}_e$ 减 1）。因此对该元素误差不变；其他元素不变，不变量保持。

情况 2：e 不在 summary 中，summary 未满。这意味着此前从未发生过驱逐。若此时出现一个未监控元素，则按 strict turnstile，它不可能先以删除的形式出现，因此当前操作只能是插入。算法把它加入 summary，并令
$$(\mathrm{ins}_e, \mathrm{del}_e) = (1, 0),$$
故此时
$$\hat{f}_e = f_e = 1.$$
其他元素不变，不变量仍成立。

情况 3：e 不在 summary 中，summary 已满，当前操作是删除。算法忽略该删除。对元素 e 而言，真实频率减少了 1，估计仍为 0，所以若更新前有

$$f_e^{(t-1)} \le m_{t-1},$$

则更新后仍有

$$f_e^{(t)} \le f_e^{(t-1)} \le m_{t-1} \le m_t,$$

因为最小 insert 计数不会因删除而减小。其他元素不变量不受影响。

情况 4：e 不在 summary 中，summary 已满，当前操作是插入。设被驱逐的元素为 x，其 insert 计数最小，为

$$w = \mathrm{ins}_x.$$

算法用新条目 e 替换 x，并设置

$$(\mathrm{ins}_e, \mathrm{del}_e) = (w+1, 0).$$

对新元素 e，在这次插入之前，它未被监控，由归纳假设，

$$f_e^{(t-1)} \le m_{t-1} = w.$$

这次插入后，

$$f_e^{(t)} \le w + 1 = \hat{f}_e^{(t)}.$$

因此它不会被低估，并且

$$\hat{f}_e^{(t)} - f_e^{(t)} \le w \le m_t.$$

对被驱逐元素 x，驱逐后它变成未被监控元素。由于

$$f_x^{(t)} \le \mathrm{ins}_x = w \le m_t,$$

因此未监控元素的条件成立。

对其余元素，估计与真实频率都未变化，不变量保持。

综上，不变量对任意更新都成立。 □

引理 4.2. *若 summary 有 m 个条目，则任意时刻*

$$m_t \le \frac{I_t}{m},$$

其中 I_t 是截至时刻 t 的总插入量。

证明. 记当前所有 monitored items 的 insert 计数之和为 S_t。我们证明

$$S_t = I_t.$$

初始时刻 $S_0 = I_0 = 0$。

- 若当前更新是已监控元素的插入，则 S_t 增加 1，同时 I_t 增加 1；

- 若当前更新是已监控元素的删除，则 S_t 不变，I_t 也不变；
- 若当前是未监控元素且 summary 未满的插入，则新建条目 $(1,0)$，故 S_t 增加 1，I_t 增加 1；
- 若当前是未监控元素、summary 已满的插入，设被驱逐条目的 insert 值为 w。驱逐后减去 w，加入新条目后加上 $w+1$，所以 S_t 净增 1，与 I_t 的变化一致；
- 若当前是被忽略的删除，则 S_t 与 I_t 都不变。

因此对所有时刻均有 $S_t = I_t$。
又由于当前有 m 个条目，其最小 insert 计数不超过平均值，所以

$$m_t \le \frac{S_t}{m} = \frac{I_t}{m}.$$

□

定理 4.3 (Integrated SpaceSaving± 的误差界)**.** *若 Integrated SpaceSaving± 使用 m 个条目，则对任意元素 e，*

$$|\hat{f}_e - f_e| \le \frac{I}{m} \le \frac{\alpha+1}{2m} F_1.$$

因此只要

$$m \ge \frac{\alpha+1}{2\varepsilon},$$

就有

$$|\hat{f}_e - f_e| \le \varepsilon F_1.$$

证明. 由引理 4.1，

$$|\hat{f}_e - f_e| \le m_t.$$

由引理 4.2，

$$m_t \le \frac{I}{m}.$$

因此

$$|\hat{f}_e - f_e| \le \frac{I}{m}.$$

再由命题 1.1，

$$I \le \frac{\alpha+1}{2} F_1.$$

于是

$$|\hat{f}_e - f_e| \le \frac{\alpha+1}{2m} F_1.$$

当 $m \ge (\alpha+1)/(2\varepsilon)$ 时，

$$|\hat{f}_e - f_e| \le \varepsilon F_1.$$

□

5 Count-Min Sketch 在 strict turnstile 与 α-bounded 下的理论保证

5.1 算法

选择 d 个独立哈希函数

$$h_r : U \to [w], \qquad r = 1, \ldots, d.$$

维护矩阵

$$C \in \mathbb{R}^{d \times w}.$$

对每个更新 (e, Δ)，执行

$$C[r, h_r(e)] \leftarrow C[r, h_r(e)] + \Delta, \qquad r = 1, \ldots, d.$$

查询时返回

$$\hat{f}_e = \min_{1 \le r \le d} C[r, h_r(e)].$$

5.2 strict turnstile 下的点查询保证

定理 5.1 (Count-Min 在 strict turnstile 下的点查询界)**.** 设最终频率向量满足 $f_e \ge 0$。若取

$$w = \left\lceil \frac{e}{\varepsilon} \right\rceil, \qquad d = \left\lceil \ln \frac{1}{\delta} \right\rceil,$$

则对任意元素 e，以至少 $1 - \delta$ 的概率有

$$f_e \le \hat{f}_e \le f_e + \varepsilon F_1.$$

证明. 固定任意一行 r。该行中与元素 e 对应的桶值为

$$C[r, h_r(e)] = f_e + \sum_{j \ne e:\, h_r(j) = h_r(e)} f_j = f_e + X_r,$$

其中

$$X_r := \sum_{j \ne e:\, h_r(j) = h_r(e)} f_j.$$

由于 strict turnstile 保证最终 $f_j \ge 0$，因此 $X_r \ge 0$，从而

$$C[r, h_r(e)] \ge f_e.$$

取多行最小值后仍有

$$\hat{f}_e \ge f_e.$$

再看碰撞误差的期望。对每个 $j \ne e$，有

$$\Pr[h_r(j) = h_r(e)] = \frac{1}{w}.$$

于是

$$\mathbb{E}[X_r] = \sum_{j \neq e} f_j \Pr[h_r(j) = h_r(e)] = \frac{1}{w} \sum_{j \neq e} f_j \leq \frac{F_1}{w}.$$

当 $w = \lceil e/\varepsilon \rceil$ 时，

$$\mathbb{E}[X_r] \leq \frac{\varepsilon}{e} F_1.$$

由 Markov 不等式，

$$\Pr[X_r \geq \varepsilon F_1] \leq \frac{\mathbb{E}[X_r]}{\varepsilon F_1} \leq \frac{1}{e}.$$

于是单行失败概率至多 $1/e$。若 d 行相互独立，则所有行都失败的概率至多

$$e^{-d} \leq \delta.$$

所以以至少 $1-\delta$ 的概率，存在某一行满足

$$C[r, h_r(e)] \leq f_e + \varepsilon F_1,$$

于是其最小值也满足

$$\hat{f}_e \leq f_e + \varepsilon F_1.$$

综上，

$$f_e \leq \hat{f}_e \leq f_e + \varepsilon F_1$$

以至少 $1-\delta$ 的概率成立。 □

5.3 α-bounded strict turnstile 下的结论

推论 5.2 (Count-Min 在 α-bounded strict turnstile 下)**.** *在 strict turnstile 且满足 α-bounded deletion 的条件下，定理 5.1 的结论保持不变：对任意元素 e，以至少 $1-\delta$ 的概率，*

$$f_e \leq \hat{f}_e \leq f_e + \varepsilon F_1.$$

所需空间仍为

$$O\left(\frac{1}{\varepsilon} \log \frac{1}{\delta}\right).$$

证明. Count-Min 的点查询分析本来就只依赖最终非负向量的 F_1。而 α-property 约束的是总更新量 $I+D$，并不会改变上述证明中关于最终频率向量的碰撞分析。因此结论原封不动成立。 □

注 5.3. 也就是说，对 point query 而言，Count-Min 在 strict turnstile 下已经直接得到

$$\hat{f}_e - f_e \leq \varepsilon F_1.$$

α-property 不会自动把这个主界再改成更强的渐近形式；它更多会影响实验中的数据 churn 程度，而不是 Count-Min 点查询的主理论界。

6 Count-Sketch 在 strict turnstile 与 α-bounded 下的理论分析

6.1 算法定义

Count-Sketch 使用 d 个哈希表，每个哈希表有 b 个桶。对每一行 $r \in [d]$，选取

$$h_r : U \to [b], \qquad s_r : U \to \{-1, +1\}.$$

维护计数数组

$$C[r, 1], \ldots, C[r, b].$$

对每个更新 (e, Δ)，执行

$$C[r, h_r(e)] \leftarrow C[r, h_r(e)] + s_r(e)\Delta, \qquad r = 1, \ldots, d.$$

对元素 e 的单行估计定义为

$$X_r(e) := s_r(e)\, C[r, h_r(e)],$$

最终估计取各行估计的中位数：

$$\hat{f}_e := \mathrm{median}_{r \in [d]}\, X_r(e).$$

注 6.1. Count-Sketch 是线性 sketch，因此天然支持正负更新；这使它本来就适用于一般 turnstile model，也当然适用于 strict turnstile model。

6.2 单行无偏性

定理 6.2 (单行估计无偏)**.** *对任意元素 e 及任意一行 r，*

$$\mathbb{E}[X_r(e)] = f_e.$$

证明. 由定义，

$$C[r, h_r(e)] = \sum_{j:\, h_r(j) = h_r(e)} s_r(j) f_j.$$

因此

$$X_r(e) = s_r(e) C[r, h_r(e)] = s_r(e) \sum_{j:\, h_r(j) = h_r(e)} s_r(j) f_j = f_e + \sum_{j \neq e} \mathbf{1}[h_r(j) = h_r(e)]\, s_r(e) s_r(j) f_j.$$

对每个 $j \neq e$，由于符号函数独立且均匀，

$$\mathbb{E}[s_r(e) s_r(j)] = 0.$$

所以

$$\mathbb{E}[X_r(e)] = f_e.$$

□

6.3 单行方差界

定义

$$F_2 := \sum_j f_j^2.$$

定理 6.3 (单行方差界)**.** *对任意元素 e 及任意一行 r,*

$$\mathrm{Var}[X_r(e)] \le \frac{1}{b}\sum_{j\neq e} f_j^2 = \frac{F_2 - f_e^2}{b} \le \frac{F_2}{b}.$$

证明. 由上节展开式,

$$X_r(e) - f_e = \sum_{j\neq e} \mathbf{1}[h_r(j) = h_r(e)]\, s_r(e) s_r(j) f_j.$$

将该式平方后取期望。因为不同元素的交叉项在随机符号下期望为 0，所以只剩对角项:

$$\mathrm{Var}[X_r(e)] = \sum_{j\neq e} f_j^2 \Pr[h_r(j) = h_r(e)].$$

而哈希均匀映射到 b 个桶,

$$\Pr[h_r(j) = h_r(e)] = \frac{1}{b}.$$

故

$$\mathrm{Var}[X_r(e)] \le \frac{1}{b}\sum_{j\neq e} f_j^2 = \frac{F_2 - f_e^2}{b} \le \frac{F_2}{b}.$$

□

6.4 高概率点查询界

定理 6.4 (Count-Sketch 的高概率点查询界)**.** *若 Count-Sketch 使用 d 行、每行 b 个桶，则对任意元素 e，存在常数 $c > 0$，使得当*

$$d = \Theta\left(\log \frac{1}{\delta}\right)$$

时，以至少 $1-\delta$ 的概率有

$$|\hat{f}_e - f_e| \le c\sqrt{\frac{F_2 - f_e^2}{b}} \le c\sqrt{\frac{F_2}{b}}.$$

特别地，当

$$b = \Theta(1/\varepsilon^2)$$

时,

$$|\hat{f}_e - f_e| \le O(\varepsilon\sqrt{F_2})$$

以至少 $1-\delta$ 的概率成立。

证明. 由定理 6.3 及 Chebyshev 不等式，对任意一行 r，

$$\Pr\left(|X_r(e) - f_e| \geq 3\sqrt{\frac{F_2 - f_e^2}{b}}\right) \leq \frac{1}{9}.$$

因此单行以至少 8/9 的概率满足

$$|X_r(e) - f_e| \leq 3\sqrt{\frac{F_2 - f_e^2}{b}}.$$

各行独立时，成功行的期望比例大于 1/2。由 Chernoff bound，当

$$d = \Theta\left(\log \frac{1}{\delta}\right)$$

时，以至少 $1-\delta$ 的概率，至少有一半以上的行满足上述误差界。于是其中位数也满足同样量级的误差界，即

$$|\hat{f}_e - f_e| \leq c\sqrt{\frac{F_2 - f_e^2}{b}}$$

对某个绝对常数 c 成立。 □

6.5 Tail-F_2 形式的更细误差界

对于 heavy hitters 分析，更有用的是 tail second moment。设 $H \subseteq U$ 是一个包含元素 e 的集合，定义

$$F_2^{\text{tail}}(H) := \sum_{j \notin H} f_j^2.$$

定理 6.5 (Tail-F_2 界)**.** *设 H 是一个包含 e 的元素集合。若某一行中，元素 e 不与 $H \setminus \{e\}$ 中的任何元素碰撞，则在该条件下有*

$$\mathbb{E}[X_r(e) \mid good] = f_e,$$

并且

$$\mathrm{Var}[X_r(e) \mid good] \leq \frac{F_2^{\text{tail}}(H)}{b}.$$

因此经过 $d = \Theta(\log(1/\delta))$ 行取 median 后，可得到

$$|\hat{f}_e - f_e| = O\left(\sqrt{\frac{F_2^{\text{tail}}(H)}{b}}\right)$$

的高概率误差界。

证明. 在 good 事件下，所有来自 $H \setminus \{e\}$ 的干扰项都不存在，因此误差项只来自 $U \setminus H$：

$$X_r(e) - f_e = \sum_{j \notin H} \mathbf{1}[h_r(j) = h_r(e)]\, s_r(e) s_r(j) f_j.$$

与定理 6.3 同理，

$$\mathrm{Var}[X_r(e) \mid \text{good}] \leq \frac{1}{b} \sum_{j \notin H} f_j^2 = \frac{F_2^{\text{tail}}(H)}{b}.$$

再对多行取中位数即可得到高概率界。 □

6.6 strict turnstile 与 α-bounded deletion 下的含义

推论 6.6 (strict turnstile 下的 Count-Sketch 保证)**.** *对于 strict turnstile stream，定理 6.2–6.5 全部保持成立。*

证明. Count-Sketch 的更新规则与分析都允许频率为有符号量；strict turnstile 只是更特殊的情形，因此这些结论直接成立。 □

推论 6.7 (α-bounded deletion 下的 Count-Sketch 保证)**.** *对于满足 α-bounded deletion 的 strict turnstile stream，Count-Sketch 的无偏性与高概率误差界保持不变：*

$$|\hat{f}_e - f_e| \le O\left(\sqrt{\frac{F_2}{b}}\right)$$

或更细地

$$|\hat{f}_e - f_e| \le O\left(\sqrt{\frac{F_2^{\text{tail}}(H)}{b}}\right).$$

但是，与 Double-MG / Double-SS / Integrated SpaceSaving± 不同，α-property 不会自动把 Count-Sketch 的 point-query 主界改写成显式的 $O(\alpha/\varepsilon)$ 形式，因为其主误差依赖于 F_2 或 tail-F_2，而不是总 L_1 churn。

注 6.8. 因此，在本项目中，Count-Sketch 最合理的角色是：

- 它是一个原生支持 strict turnstile 的随机线性 sketch；
- 理论误差界是 F_2-型或 tail-F_2-型；
- α 更适合用来解释实验中的 churn 程度变化，而不是直接改进其主理论界。

7 小结

本文给出了 strict turnstile + α-bounded deletion 模型下四类算法的理论框架：

1. Double-MG：
$$|\hat{f}_e - f_e| \le \frac{\alpha F_1}{k+1},$$
并具有 residual bound
$$|f_e - \hat{f}_e| \le \frac{I_{\text{res}}(j_+)}{k_+ + 1 - j_+} + \frac{D_{\text{res}}(j_-)}{k_- + 1 - j_-}.$$

2. Double-SS：
$$|\hat{f}_e - f_e| \le \frac{I}{m_I} + \frac{D}{m_D},$$
从而得到 $O(\alpha/\varepsilon)$ 空间界。

3. Integrated SpaceSaving±：
$$|\hat{f}_e - f_e| \le \frac{I}{m} \le \frac{\alpha+1}{2m} F_1,$$
因而同样使用 $O(\alpha/\varepsilon)$ 空间。

4. Count-Min：在 strict turnstile 下仍满足

$$f_e \le \hat{f}_e \le f_e + \varepsilon F_1$$

（以高概率），空间为

$$O\left(\frac{1}{\varepsilon}\log\frac{1}{\delta}\right).$$

参考文献

[1] Rajesh Jayaram and David P. Woodruff. Data Streams with Bounded Deletions. *arXiv:1803.08777*, 2018.

[2] David Anderson and Marios Hadjieleftheriou. A High-Performance Algorithm for Identifying Frequent Items in Data Streams. *arXiv:1705.07001*, 2017.

[3] Graham Cormode and S. Muthukrishnan. An Improved Data Stream Summary: The Count-Min Sketch and its Applications. 2004.

[4] Fuheng Zhao, Divyakant Agrawal, Amr El Abbadi, Claire Mathieu, Ahmed Metwally, and Michel de Rougemont. The SpaceSaving± Family of Algorithms for Data Streams with Bounded Deletions. *arXiv:2309.12623*, 2023.